

This is a note for the paper: Michaël Defferrard, Xavier Bresson, Pierre Vandergheynst, Convolutional Neural Networks on Graphs with Fast Localized Spectral Filtering, Neural Information Processing Systems (NIPS), 2016.

[paper](#) and [code](#) have been published by the author

## 问题背景

问题的抽象描述：一个数据被表示为一张图，一个属性为一个节点，属性用一个向量  $x \in R^d$  表示，属性之间有某种权重（比如相似度）。希望对数据进行分类，进行监督学习。

问题的一个实例：图像是特殊的图数据，像素间的距离为

$dist = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}$ ,  $(x_i, y_i)$  为像素的空间坐标。像素间权重可以取  $W_{ij} = \exp(-\frac{dist^2}{2\sigma^2})$ 。对每个像素，只取最大的k个权重，其余置为0。

另一个实例：文本分类。采用词袋模型。这时所有的词构成一张图，每个词被一个embedding vector  $v_i$  表示。词之间的权重

$W_{ij} = \exp(-\frac{\|v_i - v_j\|_2^2}{2\sigma^2})$  同样。对每个单词，只取最大的k个权重，其余置为0。

## 图上的卷积

一个图上的标准卷积是  $g * x = U\Theta U^T x$ ，其中x为图上的一个信号， $\Theta$ 为对角阵

计算量为 $O(N^2)$   $N$ 为图中的点数

设拉普拉斯矩阵 $L = U\Gamma U^T$

为了简化计算，注意到 $\Theta$ 为拉普拉斯矩阵特征值时 $g * x = Lx$

设 $\Theta \approx \sum_{i=1}^K \theta_i \Gamma^K$  (感受野大小为 $K$ )

则卷积 $g * x = U\Theta U^T x \approx U \sum_{i=1}^K \theta_i \Gamma^K U^T x = \sum_{i=1}^K \theta_i L^K x$

计算 $L^K x$ 时采用递推计算，并且一次递推是稀疏矩阵乘法，总复杂度为 $O(KE)$ ,  $E$ 为边数。由于是 $k$ 近邻图，复杂度为 $O(KkN)$   $N$ 为图中的点数

实际计算时利用了切比雪夫多项式，不过主要的思想如上。

由于输入是 $d$ 个图上的信号，因此一个卷积滤波器为对 $d$ 个信号做卷积再相加，卷积系数为可训练的参数。

如果有 $d_1$ 个卷积滤波器，则输出为图上的 $d_1$ 维信号。

## 图上的池化操作

本文中，池化操作其实是一种自底向上的层次聚类，每次将两个点聚在一起（绑定为一个节点），从而生成一个节点数大约减半的子图。选择绑定节点的方法是 $\max W_{ij}(\frac{1}{d_i} + \frac{1}{d_j})$ , 每次固定 $i$ ，选择使上述normalized cut最大的点 $j$ ，然后绑定它们，作为一个新节点，新节点的权重为之前两个节点权重的和。（开源代码中优先对度小的点进行配对）

由此可以逐级定义子图，即对绑定的节点进行pooling操作。

我重点阅读了coarsening，即pooling的开源代码

卷积神经网络最重要的三个功能：局部感受野、参数共享、池化操作，在这篇图卷积网络中也就都实现了。

KIPF的GCN中每个输入的数据是一个节点，图规模随数据增加而增大，训练方法是半监督学习。而DEFFER的GCN中，每个输入的数据被建模为一个图，数据类型给定则图规模就定了，图规模不会随数据量增大而增大。训练方法是监督学习，很像传统的CNN。